

Week 1 Problem Set

Attention 如何按内容读取信息？

本周能力 用推导、反例、Lab 与故障诊断掌握单头 attention。

完成后解锁 causal mask 在 score 到 softmax 数据流中的位置。

课程位置与提交规则

本题集覆盖单样本、单头、NumPy 前向计算。它不要求 batch、多头、位置编码、Transformer block 或训练。

前置能力：Week 0 的矩阵 shape、点积和投影证据已通过。若闭卷桥接出现关键 shape 或 $K^\top$ 错误，先回到 Week 0。

完成顺序：

1. Part A–D 在 Lab 前完成；
2. 独立实现 softmax、project_qkv 与 scaled_dot_product_attention；
3. Part E 和迁移任务引用自己的 Lab 证据。

禁止项：不要查看隐藏评分样例、参考实现或答案。不要用代码运行替代手算和预测。

Part A：前置桥接与 Q/K/V

A1. 闭卷 shape 桥接 (Week 0 $\rightarrow$ Week 1)

令 token 表 $X \in \mathbb{R}^{3 \times 4}$ ，三个投影矩阵 $W_Q, W_K, W_V \in \mathbb{R}^{4 \times 2}$ 。

- (1) 写出 $Q = XW_Q$ 、 $K = XW_K$ 、 $V = XW_V$ 的 shape。
- (2) 写出 $QK^\top$ 、row-wise softmax 后的 weights，以及 weights V 的 shape。
- (3) 用一句话说明 $\text{scores}[i, j]$ 中 i 和 j 分别指向谁。
- (4) 解释输出的特征宽度为什么来自 V ，而不是 Q 或 token 数。

A2. 投影改变表示，不改变 token 对应关系 (推导)

自行选择一个 $X \in \mathbb{R}^{2 \times 2}$ 和一个非单位 $W_Q \in \mathbb{R}^{2 \times 2}$ 。

- (1) 手算 $Q = XW_Q$ 的一个输出位置。
- (2) 标注 Q 的两维分别代表什么。
- (3) 解释为什么投影后第 i 行仍然属于原来的第 i 个 token。

A3. 只改变 W_V (预测)

保持 X, W_Q, W_K 不变，只改变 W_V 。在运行任何代码前，分别预测 Q、K、V、scores、weights 与 output 是否必须保持不变，并为每项写一句理由。

Part B : score、转置与缩放

B1. 两个 queries 对三个 keys (推导)

给定

$$Q = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}, \quad K = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}.$$

- (1) 写出 $QK^\top$ 的 shape 并手算完整矩阵。
- (2) 对每个 query，先预测哪个 key 的 score 最大，再用结果验证。
- (3) 逐项解释 $\text{scores}[0, 2]$ 与 $\text{scores}[1, 0]$ 。
- (4) 说明同一行中是谁在竞争后续权重。

B2. 为什么转置必须发生在 K 上 (反例)

构造一组 Q、K，使 QK 不能计算或语义与“每个 query 比较所有 keys”不符，但 $QK^\top$ 合法。

- (1) 写出两个输入 shape。
- (2) 写出错误运算与正确运算的输出 shape。
- (3) 解释转置错误为什么可能在某些方阵输入下悄悄通过 shape 检查。

B3. 缩放依赖 d_k , 不是 token 数 (机制)

假设 Q、K 的各元素均值为 0、方差为 1，且不同维近似独立。

- (1) 将 dot product 写成 d_k 个乘积项之和。
- (2) 说明其方差为什么随 d_k 增长。
- (3) 解释除以 $\sqrt{d_k}$ 如何缓解 softmax 饱和。
- (4) 构造 token 数相同但 d_k 不同的两个场景，说明为什么不能除以 token 数。

Part C : stable row-wise softmax

C1. 平移不变性 (证明)

证明对任意向量 z 和常数 c ,

$$\text{softmax}(z) = \text{softmax}(z - c\mathbf{1}).$$

随后说明稳定实现为什么选择 $c = \max_i z_i$ 。

C2. 极端数值 (预测后验证)

对 $z = [1000, 999, 998]$:

- (1) 预测直接计算 e^z 的数值风险。
- (2) 写出减去最大值后的向量。
- (3) 不使用计算器判断三个权重的相对大小。
- (4) 写出实现必须保持的三个性质 : shape、有限性和归一化。

C3. 错误 axis (反例)

构造一个 2×3 score 矩阵，使沿 $\text{axis}=-1$ 与 $\text{axis}=0$ 的结果有明显不同。

- (1) 分别说明两种 axis 下是谁在竞争概率。
- (2) 写出两种结果应分别在哪个维度上和为 1。
- (3) 说明错误 axis 为什么可能仍返回正确 shape。

Part D : 从 weights 读取 V

D1. 输出宽度来自 V (推导)

设 weights 为 (n_q, n_k) ，V 为 (n_k, d_v) 。

- (1) 写出 weights V 的输出 shape。
- (2) 展开一个输出位置，说明它聚合的是 V 的哪一行。
- (3) 解释为什么 key 数必须等于 V 的行数。

D2. 只改变一行 V (预测后验证)

自行构造两个 queries、三个 keys 和三行 V。保持 Q/K 不变，只改变 V 的一行。

- (1) 运行前预测 scores 与 weights 是否变化。
- (2) 预测哪些 output 行可能变化以及变化大小受什么控制。
- (3) 用最小 NumPy 实验验证，并记录预测与结果是否一致。

D3. 完整 attention 数据流 (闭卷)

写出并标注每一步 shape :

$$X \rightarrow Q, K, V \rightarrow QK^T \rightarrow \frac{QK^T}{\sqrt{d_k}} \rightarrow \text{weights} \rightarrow \text{output}.$$

在每条箭头旁说明它改变的是 token 数、特征宽度、匹配语义还是归一化语义。

Part E : Lab 后工程问题

以下问题必须引用自己的实现、输入、断言、grader 类别或 demo 观察。

E1. 函数契约与错误所有权

分别为 softmax、project_qkv 和 scaled_dot_product_attention 选择一个应由该函数直接拒绝的输入。写出输入 shape、预期异常类型，以及若把错误拖到后续才发现会增加什么排查成本。

E2. Shape 正确但机制错误

构造一个输出 shape 正确、数值也有限，但机制错误的实现反例。它违反 score、缩放、softmax axis 或 value read 中哪条契约？设计一个公开性质检查来发现它。

E3. 一个真实或主动注入的失败

记录：

- (1) 输入与现象；
- (2) grader 或自己的错误类别；
- (3) 原因假设；
- (4) 区分假设的最小验证；
- (5) 修复后重新成立的性质；
- (6) 下次提前发现它的预防策略。

E4. 从 Lab 到独立 demo 的取舍

解释 attention inspector 为什么应调用公开接口，而不是复制 Lab 内部实现。指出 inspector 必须自行决定的三个呈现或验证边界。

独立迁移：Attention Inspector

构建一个不复制 attention 内部实现的小型 inspector，显示 Q、K、V、scores、weights 和 output 的 shape，并展示指定一行 weights 的摘要。

运行前预测：

- (1) 哪个 query 最关注哪个 key？为什么？
- (2) 只改变一行 V 后，哪些量必须保持不变？哪些 output 可能变化？

提交证据：输入、两项预测、实际输出、差异解释，以及一个没有复制 Lab 内部实现的接口说明。

闭卷自检与提交清单

不看材料，用 3–5 分钟回答：attention 接收什么、计算什么、输出什么、为什么需要缩放，以及一种 shape 正确但机制错误的失败方式。

- ☐ Part A–D 已在 Lab 前独立完成。
- ☐ 所有 P0 Lab 检查通过，没有未解释的 shape、axis、数值稳定性或 value read 缺口。
- ☐ Part E 引用了自己的真实实现或评分证据。
- ☐ 完成一个未见过的数值迁移题和一个主动注入或真实故障。
- ☐ attention inspector 没有复制 Lab 内部实现，并完成两项预测后验证。
- ☐ 能够指出 causal mask 应插在 softmax 前，并说明本周为什么不实现它。

未关闭的 P0 缺口会阻止进入 causal mask。