

Week 0 Resources

看懂每一步信息如何变化

如何使用这份资源栏

本周不泛读。每份材料只服务于从 token 表到 Week 1 attention 的一段信息流。
读完一项后立即回答阅读问题并留下完成证据；答不出时只回读该项，不追加新材料。

1. Linear Algebra：让 shape 可预测

链接：[D2L 2.3 Linear Algebra](#)

精确范围：只读 Scalars、Vectors、Matrices、Tensors、Reduction、Non-Reduction Sum。
继续读 Dot Products、Matrix-Vector Products、Matrix-Matrix Multiplication；跳过范数、导数和特征分解。

带着的问题读：若 $X \in \mathbb{R}^{3 \times 2}$ 、 $W \in \mathbb{R}^{2 \times 2}$ ，为什么 $XW \in \mathbb{R}^{3 \times 2}$ ？输出元素 $(XW)_{i,j}$ 从哪里来？

完成证据：写出内维度规则，并手算一个输出元素。

2. Softmax：将 score 变成权重

链接：[D2L 4.1 Softmax Regression](#)

精确范围：只读 Softmax Operation、Vectorization、Loss Function 与 Information Theory Basics。
本周不实现 softmax regression。

带着的问题读：为什么 score 需要被归一化为权重？为什么

$$\text{softmax}(z) = \text{softmax}(z - \max_i z_i)$$

允许稳定计算？

完成证据：对 $z = [2, 1, 0]$ 手算 softmax，并说明同加常数后为何不变。

3. Queries, Keys, Values：建立 attention 直觉

链接：[D2L 11.1 Queries, Keys, and Values](#)

精确范围：只读开头的 Queries, Keys, and Values 定义，以及 attention pooling 的直觉与 summary。
不进入实现代码和后续章节。

带着的问题读：dot product 为什么可以作为 query 与 key 的匹配分数，却不能直接作为最终读取结果？

完成证据：写出一个两 token 的点积例子，并指出它还缺少哪一步才会成为读取权重。

4. 原始论文：定位完整模型，而非推导公式

链接：[Attention Is All You Need](#)

精确范围：只读 abstract 和 Figure 1。只看 encoder-decoder 的整体数据流；不读公式与第 3 节细节。

带着的问题读：token 的顺序信息、attention 和输出预测大致位于整张图的哪里？

完成证据：画一条从 token 到预测的粗略箭头图，标出 Week 0 已经认识的操作。

停止规则与下一步

完成四项后停止阅读，转入 Week 0 的任务与概念作业。Week 1 才精读论文第 3.2.1 节的 scaled dot-product attention。