

Week 1 Learning Guide

Attention 如何按内容读取信息？

本周能力 独立解释、实现并诊断单头 scaled dot-product attention。

完成后解锁 在同一数据流中判断 causal mask 应插入的位置。

开始之前

本周只处理单样本、单头、NumPy 前向计算，不进入 batch、多头、位置编码、Transformer block 或训练。

闭卷桥接：令 X 为 $(3, 4)$ ，三个投影矩阵均为 $(4, 2)$ 。不看代码写出 Q 、 K 、 V 、 $QK^\top$ 、weights 和 weights V 的 shape，并解释 $\text{scores}[i, j]$ 中 i 与 j 各指向谁。

若无法解释 $K^\top$ 或内维度，回到 Week 0；不要靠运行 Lab 猜 shape。

本周规则：

- 先预测、手算和解释，再进入 Lab。
- hidden grader 只返回失败类别与思考提示，不提供样例或答案。
- 一次运行成功不等于掌握；还需要真实故障和独立迁移证据。

本周 Gate 路线

Gate 0：调用 Week 0 前置能力

通过证据：所有 shape 闭合，能解释 $K^\top$ ，并区分 score、weight 与 output；否则回退 Week 0。

Gate 1：Q/K/V 的职责

通过证据：完成一张 Q/K/V shape 表，并预测只改变 W_V 时哪些量保持不变。

Gate 2：score 的行列语义

通过证据：手算两个 queries 对三个 keys 的 score，解释 $\text{scores}[i, j]$ ，并构造一次转置错误。

Gate 3：缩放与 stable softmax

通过证据：证明平移不变性，处理 $[1000, 999, 998]$ ，构造错误 axis 反例，并解释 $\sqrt{d_k}$ 。

Gate 4：从 weights 读取 V

通过证据：先预测后验证一次“只改变 V”的实验，并解释输出宽度为何来自 V。

Gate 5：受约束实现

通过证据：依次通过 softmax、Q/K/V 投影和 scaled dot-product attention 的公开与 hidden 检查。

Gate 6：故障诊断与独立迁移

通过证据：解释一次真实或主动注入错误，并完成不复制 Lab 内部实现的 attention inspector。

精确阅读材料

1. DeepLearning.AI : 先建立整体直觉

链接 : [Transformers in Practice](#)

精确范围 : Module 2 'LLM internals and attention' 中的 Attention (8 分钟)、Visualization: Decoder-Only Transformers (10 分钟) 和 Visualization: Interpretable Attention Heads (10 分钟)。只建立直觉, 不把可视化当成公式或实现答案。

阅读问题 : 一个 token 的表示何时开始依赖其他 token ? 可视化与 Q/K/V 计算之间还缺什么机制解释 ?

完成证据 : 记录页面显示的三个 lesson 名称, 并画一条 token 表到 attention output 的粗略箭头图。

2. D2L 11.1 : 分开 query、key 与 value

链接 : [Queries, Keys, and Values](#)

精确范围 : 只读 11.1.1 的定义、attention pooling 公式与图 11.1.1, 再读 11.1.2 Summary ; 跳过框架代码与练习。

阅读问题 : 匹配权重和被读取内容分别由谁决定 ?

完成证据 : 用自己的两个 key-value 对构造一个 query, 并分别解释 Q、K、V。

3. D2L 11.3 : 读懂 score、缩放与输出

链接 : [Attention Scoring Functions](#)

精确范围 : 读引言、11.3.1、11.3.2.1 的归一化语义, 以及 11.3.3 的公式 (11.3.6) 与 shape ; 跳过 batch 代码、additive attention 和练习。

阅读问题 : 为什么 score 沿 key 维竞争 ? 为什么缩放依赖 d_k ? 输出宽度为什么来自 V ?

完成证据 : 写出 QK^T 、weights、weights V 的 shape, 并构造错误 axis 反例。

4. 原始论文 3.2.1 : 回到公式定义

链接 : [Attention Is All You Need](#)

精确范围 : 只读 3.2.1 Scaled Dot-Product Attention 的公式、缩放理由与文字说明 ; 跳过 3.2.2 multi-head、后续 block 与训练。

阅读问题 : 论文为什么用 $\sqrt{d_k}$? Q/K 参与匹配而 V 决定输出, 如何在公式中体现 ?

完成证据 : 用自己的 (2, 2) 数值例子解释一次 score、softmax 与 value 加权。

进入 Lab 前必须留下的证据

- ☐ Q、K、V、scores、weights 与 output 的 shape 表。
- ☐ 一个 $\text{scores}[i, j]$ 的行列解释和转置错误反例。
- ☐ 对 $[1000, 999, 998]$ 的 stable softmax 预测与平移不变性推导。

- ☐ 一个能区分 $\text{axis}=-1$ 与 $\text{axis}=0$ 的二维数组。
- ☐ 只改变一行 V 时，对 scores 、 weights 与 output 的变化预测。

缺少任一 P0 证据时，回到对应 Gate；不要用测试输出代替推导。

Lab 与提示协议

```
uv run pytest labs/week-01/tests -v
uv run python labs/week-01/run_grade.py
```

第 1 次失败：阅读失败类别对应的思考问题，先写原因假设。

第 2 次失败：打印相关张量的 shape 和一行数值，用最小输入区分假设。

第 3 次失败：回到本周理论 Gate，不请求完整实现答案。

grader 不存在时只能说明本地未配置验证器，不能据此判定通过或失败。

完成与提交清单

- ☐ Gate 0–4 的概念、推导和反例证据完整。
- ☐ Lab 的公开与 hidden P0 检查通过。
- ☐ 工程作业引用了自己的输入、断言、grader 类别或 demo 观察。
- ☐ 记录并解释一个真实或主动注入的失败。
- ☐ 能在 3–5 分钟内闭卷解释输入、计算、输出、必要性和一种失败。
- ☐ `attention inspector` 调用公开接口，没有复制 Lab 内部实现。
- ☐ 先预测后验证了“哪个 query 关注哪个 key”和“只改变一行 V ”两个实验。

全部完成后只解锁 `causal mask` 的位置问题；不会自动跳到 `multi-head` 或训练。